Datenstrukturen, Algorithmen und Programmierung 2

Amin Coja-Oghlan

June 29, 2023

Lehrstuhl Informatik 2 Fakultät für Informatik



Worum geht es?

- Datenstrukturen sind wichtige Hilfsmittel der Algorithmik
- Beispiele: Stacks, Splay Trees, Fibonacci Heaps...
- Die meisten Operationen benötigen wenig Zeit
- Ab und zu ist aber "Aufräumen" nötig
- Idee: Analyse der Gesamtlaufzeit durch kreative Buchführung



Datenstruktur Stapel

- Funktionalität: push, pop, empty
- Abzubilden im Hauptspeicher ('random access')
- Zahl der zu speichernden Einträge a priori unbekannt
- Ziel: Zeit- und Speicherplatzeffizienz.



- Reserviere einen Speicherblock der Größe *n*
- Anfangs n = 1
- Wenn der Block voll ist, reserviere einen Block der Größe 2n
- Kopiere den Inhalt des alten Blocks in den neuen
- lacktriangledown \sim einzelne push-Operation zeitintensiv
- (Freigeben von Speicherplatz normalerweise einfacher.)



- Reserviere einen Speicherblock der Größe *n*
- Anfangs n = 1
- Wenn der Block voll ist, reserviere einen Block der Größe 2n
- Kopiere den Inhalt des alten Blocks in den neuen
- ~> einzelne push-Operation zeitintensiv
- (Freigeben von Speicherplatz normalerweise einfacher.)



- Reserviere einen Speicherblock der Größe *n*
- Anfangs n = 1
- Wenn der Block voll ist, reserviere einen Block der Größe 2n
- Kopiere den Inhalt des alten Blocks in den neuen
- lacktriangledown \sim einzelne push-Operation zeitintensiv
- (Freigeben von Speicherplatz normalerweise einfacher.)





- Reserviere einen Speicherblock der Größe *n*
- Anfangs n = 1
- Wenn der Block voll ist, reserviere einen Block der Größe 2*n*
- Kopiere den Inhalt des alten Blocks in den neuen
- lacktriangledown \sim einzelne push-Operation zeitintensiv
- (Freigeben von Speicherplatz normalerweise einfacher.)





- Reserviere einen Speicherblock der Größe *n*
- Anfangs n = 1
- Wenn der Block voll ist, reserviere einen Block der Größe 2*n*
- Kopiere den Inhalt des alten Blocks in den neuen
- lacktriangledown \sim einzelne push-Operation zeitintensiv
- (Freigeben von Speicherplatz normalerweise einfacher.)





- Reserviere einen Speicherblock der Größe *n*
- Anfangs n = 1
- Wenn der Block voll ist, reserviere einen Block der Größe 2*n*
- Kopiere den Inhalt des alten Blocks in den neuen
- lacktriangledown \sim einzelne push-Operation zeitintensiv
- (Freigeben von Speicherplatz normalerweise einfacher.)





- Reserviere einen Speicherblock der Größe *n*
- Anfangs n = 1
- Wenn der Block voll ist, reserviere einen Block der Größe 2*n*
- Kopiere den Inhalt des alten Blocks in den neuen
- lacktriangledown \sim einzelne push-Operation zeitintensiv
- (Freigeben von Speicherplatz normalerweise einfacher.)





- Reserviere einen Speicherblock der Größe *n*
- Anfangs n = 1
- Wenn der Block voll ist, reserviere einen Block der Größe 2*n*
- Kopiere den Inhalt des alten Blocks in den neuen
- lacktriangledown \sim einzelne push-Operation zeitintensiv
- (Freigeben von Speicherplatz normalerweise einfacher.)





- Reserviere einen Speicherblock der Größe *n*
- Anfangs n = 1
- Wenn der Block voll ist, reserviere einen Block der Größe 2*n*
- Kopiere den Inhalt des alten Blocks in den neuen
- lacktriangledown \sim einzelne push-Operation zeitintensiv
- (Freigeben von Speicherplatz normalerweise einfacher.)

Beispiel: *N*×push, *N*×pop

- Nehmen wir an, $N = 2^k$ ist eine Potenz von 2.
- Dann wird bei den push-Operationen

2, 3, 5, 9, 17, ...,
$$2^{k-1} + 1$$

jeweils die Größe des Speicherblocks verdoppelt.

Der Zeitbedarf für die letzte Verdopplung allein ist

$$2^{k-1} + 1 > N/2$$
.

Naive Analyse: Zeitbedarf $O(N^2)$

Amortisierte Analyse

- Angenommen insgesamt *N* push-Operationen
- Behauptung: Gesamtlaufzeit O(N)



Amortisierte Analyse

- Angenommen insgesamt *N* push-Operationen
- Behauptung: Gesamtlaufzeit O(N)
- Direkte Analyse: Zeitaufwand für Reallokation.
- Mit $\ell = \lceil \log_2 N \rceil$ ist dieser beschränkt durch

$$\sum_{i=1}^{\ell} 2^{i-1} = \sum_{i=0}^{\ell-1} 2^i \le 2^{\ell} = O(N).$$



Amortisierte Analyse

- Angenommen insgesamt *N* push-Operationen
- Gesamtlaufzeit O(N)
- Die amortisierte Laufzeit pro push ist also O(1)



Informelle Definition

■ Angenommen die tatsächlichen Kosten einer Folge von Operationen sind

$$c_1, c_2, \ldots, c_N \geq 0$$

■ Sei c'_1, \ldots, c'_N eine weitere Folge, so daß

$$c_1 + c_2 + \cdots + c_i \leq c'_1 + c'_2 + \cdots + c'_i$$

für alle $1 \le i \le N$.

- Dann ist c'_1, \ldots, c'_N eine Amortisierung von c_1, \ldots, c_N .
- Die amortisierten Gesamtkosten sind $c'_1 + \cdots + c'_N$.



Woche	Kosten	Amortisierung
1	$c_1 = 0$	$c_1' = 10$
2	$c_2 = 0$	$c_2' = 10$
3	$c_3 = 0$	$c_3^7 = 10$
4	$c_4 = 0$	$c_4' = 10$
5	$c_5 = 50$	$c_{5}^{\prime} = 10$

Beispiel Fahrrad

- Angenommen ich radle täglich zur Uni
- Die meisten Tage entstehen keine Kosten
- Aber gelegentlich entstehen (relativ) hohe Reparaturkosten
- *Idee*: lege diese Kosten auf alle Tage/Kilometer um...
- ...um die Gesamtkosten einfacher kalkulieren zu können



Potentialfunktionen

- Wie findet man eine geeignete Amortisierung?
- Hilfsmittel: Potentialfunktion $\Phi: \mathcal{Z} \to \mathbb{R}_{>0}$
- *Idee*: Φ misst die 'Unordnung' des aktuellen Zustands
- Für eine leere Datenstruktur gelte $\Phi(\emptyset) = 0$
- Wenn $z_0 = \emptyset, z_1, ..., z_N$ die Zustände der Datenstruktur sind, definiere

$$c_i' = c_i + \Phi(z_i) - \Phi(z_{i-1})$$



Potentialfunktionen

■ Wir definieren

$$c'_{i} = c_{i} + \Phi(z_{i}) - \Phi(z_{i-1}) \qquad (i \ge 1)$$

- Behauptung: $c_1 + \cdots + c_i \le c'_1 + \cdots + c'_i$ für alle i
- Zum Beweis berechnen wir

$$c'_{1} + \dots + c'_{i} = (c_{1} + \Phi(z_{1}) - \Phi(z_{0})) + \dots + (c_{i} + \Phi(z_{i}) - \Phi(z_{i-1}))$$

$$= c_{1} + \dots + c_{i} + (\Phi(z_{1}) - \Phi(z_{0})) + \dots + (\Phi(z_{i}) - \Phi(z_{i-1}))$$

$$= c_{1} + \dots + c_{i} + \Phi(z_{i}) - \Phi(z_{0})$$

$$= c_{1} + \dots + c_{i} + \Phi(z_{i}) \ge c_{1} + \dots + c_{i}$$



Analyse via Potentialfunktion

 \blacksquare Der Zustand z_i besteht aus

$$b_i$$
 = #belegte Plätze,

 n_i = reservierter Speicherplatz

■ Wir definieren

$$\Phi(z_i) = \max\{0, 2b_i - n_i\}$$



Analyse via Potentialfunktion

- Die Potentialfunktion ist $\Phi(z_i) = \max\{0, 2b_i n_i\}$
- Amortisierte Kosten:

$$c'_{i} = 3$$

 $c'_{i} = 3$
 $c'_{i} = -1$

für push ohne Vergrößern für push mit Vergrößern für pop

- Also $c'_i = O(1)$ für alle i
- Folglich $c_1 + \cdots + c_N = O(N)$



Weitere Beispiele

- Splay trees: amortisiert $O(\log n)$ search, insert, delete
- Dictionary: amortisiert $O(\log n)$ insert
- Fibonacci heap: amortisiert O(1) insert, findMin, decKey; $O(\log n)$ delMin



Anwendung: Dijkstra-Algorithms

Satz

Der Dijkstra-Algorithmus hat Laufzeit $O(|E_G| + |V_G| \log |V_G|)$.

Beweis

- Jeder Knoten wird nur einmal der Halde hinzugefügt/entfernt
- Gesamtaufwand dafür ist $O(|V_G| \log |V_G|)$
- Ferner wird für jede Kante einmal decKey aufgerufen
- Laufzeit dafür O(|E|)



Zusammenfassung

- Amortisierung ist ein Analysewerkzeug für Datenstrukturen
- Ziel: Gesamtlaufzeit über viele Operationen bestimmen
- Hilfsmittel: Potentialfunktionen
- Einschränkungen: z.B. kritische Reaktionszeiten